

Tarea – Consultas Básicas a Base de Datos no Relacionales con MongoDB

Estudiante:

Heiner Romero Leiva

Máster en Big Data & Data Science

Noviembre, 2021



Descripción de la tarea:

Has sido contratado por una consultora como Data Engineer. Se te da acceso a una base de datos no relacional, la cual está montada en un servidor MongoDB.

Dentro de la base de datos existen varias colecciones:

Colección	Descripción	Documentos
companies	Contiene información sobre las grandes empresas de la actualidad.	18801
mails	Contiene emails (asunto, destinatarios, mensaje, etc.).	5929
neighborhoods	Contiene información geo posicionada de barrios/ciudades del Reino Unido.	195
restaurants	Contiene información sobre restaurantes de varias ciudades de Reino Unido.	25359
zips	Contiene información sobre códigos postales de EEUU.	29467

Debes crear las consultas necesarias para poder responder a las siguientes preguntas:

- 1. ¿Cuántos restaurantes pertenecen a la ciudad (borough) de "Queens"?
- 2. ¿Cuántos restaurantes tienen el código postal 11374?
- 3. ¿Cuántos restaurantes son de tipo "American" o "Bakery"?
- 4. ¿Cuántos nombres de restaurantes empiezan por la letra "A"?
- 5. ¿Cuáles es el nombre de las 10 empresas mas antiguas?
- 6. ¿Cuántas empresas se fundaron durante o después del año 2000?
- 7. ¿Cuántas empresas tienen entre 500 y 1000 empleados/as?
- 8. ¿Cuántas empresas no tienen productos informados?
- 9. ¿En cuántos mails aparecen las palabras "Wall Street Journal" en el asunto del correo?
- 10. ¿Cuántos correos tienen como remitente un correo con dominio @enron.com?

Antes de empezar a responder las preguntas, es necesario inspeccionar cada una de las colecciones con que se cuenta, ya que es necesario conocer cada uno de los campos y familiarizarse con ellos, por ello lo primero que se hace es visualizar con el commando "findOne" cada una como se muestra a continuación.

Companies:

Query:

db.companies.findOne()

Mails:

Query:

db.mails.findOne()

Neighborhoods:

Query:

db.neighborhoods.findOne()

Restaurants:

Query:

db.restaurants.findOne()

Zips:

Query:

db.zips.findOne()

Una vez hecho esto y habiendo visto cuáles son los nombres de los campos, se puede empezar el ejercicio propuesto.

1. ¿Cuántos restaurantes pertenecen a la ciudad (borough) de "Queens"?

Para realizar este ejercicio se utilizan dos tipos diferntes de sentencias, una con comillas y con "\$eq", y otra estándar sin comillas y ambos dan el mismo resultado, que son **5656 restaurantes que pertenecen a la ciudad de Queens**.

Queries:

db.restaurants.find({"borough": {"\$eq": "Queens"}}).count()

```
> db.restaurants.find({"borough": {"$eq": "Queens"}}).count()

< 5656

> | Activar Windows

Ve a Configuración para activar Windows
```

db.restaurants.find({borough: "Queens"}).count()

db.restaurants.find({borough : "Queens"}).pretty()

2. ¿Cuántos restaurantes tienen el código postal 11374?

Para este caso, también se hace una comprobación usando el comando "\$eq" y sin él, dando el mismo resultado; es decir, 88 restaurantes tienen el código 11374, luego se hace una comprobación con la consulta para verificar que efectivamente retorna un resultado válido con el código 11374 con el que estamos filtrando.

db.restaurants.find({"address.zipcode": "11374"}).count()

```
> db.restaurants.find({"address.zipcode": "11374"}).count()
< 88
```

db.restaurants.find({"address.zipcode": {"\$eq": "11374"}}).count()

```
> db.restaurants.find({"address.zipcode": {"$eq": "11374"}}).count()

< 88

Ve a Configuración para activar Windows
```

db.restaurants.find({"address.zipcode": "11374"})

3. ¿Cuántos restaurantes son de tipo "American" o "Bakery"?

La cantidad de restaurantes que son de tipo "American" o "Bakery" es de 6874, de igual forma se coteja el resultado para verificar que efectivamente la consulta está tomando en cuenta "American" como "Bakery" tal y como se muestra a continuación.

db.restaurants.find({"\$or": [{"cuisine": "American"}, {"cuisine": "Bakery"}]}).count()

```
> db.restaurants.find({"$or": [{"cuisine": "American"),{"cuisine": "Bakery"}]}).count()

Activar Windows

Ve a Configuración para activar Winc
```

db.restaurants.find({\$or: [{cuisine: "American"}, {cuisine: "Bakery"}]}).count()

```
> db.restaurants.find({$or: {{cuisine: "American"},{cuisine: "Bakery"}}}).count()

Activar Windows

Ve a Configuración para activar Windows
```

db.restaurants.find({\$or: [{cuisine: "American"},

{cuisine: "Bakery"}]}).sort({cuisine: -1}).limit(2)

db.restaurants.find({\$or: [{cuisine: "American"},

{cuisine: "Bakery"}]}).limit(7)

4. ¿Cuántos nombres de restaurantes empiezan por la letra "A"?

La cantidad de restaurantes que empiezan con la letra "A" es de 1126. De igual forma se adjunta captura de la consulta de verificación.

db.restaurants.find({"name": /^A/}).count()

```
> db.restaurants.find({"name": /^A/)).count()
< 1126
```

db.restaurants.find({"name": /^A/}, {"name": 1})

5. ¿Cuáles es el nombre de las 10 empresas mas antiguas?

Se adjunta captura de pantalla con el nombre de las 10 empresas ordenadas en forma ascendente con respecto al "founded_year".

```
db.companies.find({"founded_year": ("$ne": null}), {"name": 1, "founded_year": 1, "_id": 0)).sort({"founded_year": 1}).limit(10)

<{ name: 'SaallWorlda', founded_year: 1800 }
 { name: 'US Army', founded_year: 1800 }
 { name: 'Alstrasoft', founded_year: 1800 }
 { name: 'DuPont', founded_year: 1802 }
 { name: 'Bachmann Industries', founded_year: 1833 }
 { name: 'McKesson', founded_year: 1833 }
 { name: 'McKesson', founded_year: 1835 }
 { name: 'Accuity', founded_year: 1836 }
 { name: 'CENTRA', founded_year: 1839 }
 { name: 'CENTRA', founded_year: 1840 }
}</pre>
```

6. ¿Cuántas empresas se fundaron durante o después del año 2000?

La cantidad de empresas que se fundaron durante o después del año 2000 asciende a 10742. Se adjunta captura de la verificación de la consulta tanto a nivel del límite inferior (2000) como del límite superior (más alejadas del año 2000).

db.companies.find({"founded year": {"\$gte": 2000}}).count()

```
> db.companies.find({"founded_year": {"$gte": 2000}}).count()
< 10742
>
```

db.companies.find({"founded_year": {"\$gte": 2000}}, {"name": 1, "founded_year": 1, "_id": 0}).sort({"founded_year": -1}).limit(10)

db.companies.find({"founded_year": {"\$gte": 2000}}, {"name": 1, "founded_year": 1, "_id": 0}).sort({"founded_year": 1}).limit(10)

7. ¿Cuántas empresas tienen entre 500 y 1000 empleados/as?

La cantidad de empresas asciende a 144. Se adjuntan capturas del límite inferior (más cercanas o iguales a 500) y del límite superior (más cercanas o iguales a 1000).

db.companies.find({"number_of_employees": {"\$gte": 500, "\$lte": 1000}}).count()

```
> db.companies.find({"number_of_employees": {"$gte": 500, "$lte": 1000}}).count()
< 144
>
```

 $\label{lem:companies.find} $$ db.companies.find({"number_of_employees": {"$gte":500,"$lte":1000}},{"number_of_employees": 1, "name": 1, "_id": 0}).sort({"number_of_employees": 1}).limit(10)$

 $\label{lem:companies.find} $$ db.companies.find({"number_of_employees": {"$gte":500,"$lte":1000}}, {"number_of_employees": 1, "name": 1, "_id": 0}).sort({"number_of_employees": -1}).limit(10)$

```
> db.companies.find({"number_of_employees": {"$gte": 500, "$lte": 1000}), {"number_of_employees": 1, "name": 1, "_id": 0}).sort({"number_of_employees": -1}).li

{ name: 'Telenav', number_of_employees: 1000 }
{ name: 'Yatra online', number_of_employees: 1000 }
{ name: 'Yatra online', number_of_employees: 1000 }
{ name: 'Sonus Networks', number_of_employees: 1000 }
{ name: 'Yodle', number_of_employees: 1000 }
{ name: 'Antal International', number_of_employees: 1000 }
{ name: 'Gumtree', number_of_employees: 1000 }
{ name: 'Sonus Networks', number_of_employees: 1000 }
{ name: 'Sonus Networks', number_of_employees: 1000 }
{ name: 'Aktal International', number_of_employees: 1000 }
{ name: 'Aktal International', number_of_employees: 1000 }
{ name: 'Aktal Technologies', number_of_employees: 1000 }
}
```

8. ¿Cuántas empresas no tienen productos informados?

La cantidad de empresas sin productos informados asciende a 13282. De igual forma se adjunta captura de pantalla con la comprobación.

db.companies.find({"products": { "\$eq": [] }}).count()

```
> db.companies.find({"products": {"$eq": []}}).count()
< 13282
>
```

db.companies.find({"products": [] }).count()

```
db.companies.find(("products": [])).count()
< 13282
</pre>
```

 $db.companies.find(\{``products": \{ "\$eq": [] \} \}, \{``products": 1, ``name": 1, ``_id": 0 \}).limit(10) \\$

```
db.companies.find(("products": ("$eq": []}), ("products": 1, "name": 1, "_id": 0}).limit(10)

({ name: 'AdventNet', products: [] }

{ name: 'Fox Interactive Media', products: [] }

{ name: 'Scribd', products: [] }

{ name: 'StumbleUpon', products: [] }

{ name: 'Vaccom', products: [] }

{ name: 'JotSpot', products: [] }

{ name: 'NetRatings', products: [] }

{ name: 'NetRatings', products: [] }

{ name: 'YouTube', products: [] }
```

9. ¿En cuántos mails aparecen las palabras "Wall Street Journal" en el asunto del correo?

Dicha palabra aparece 4 veces. Se adjuntan capturas de pantalla con la comprobación; además se adjunta una captura sin el comando "\$regex" para verificar si habían resultados, pero dichas palabras aparecen con la composición "Millennium Forum", por ello aparece como "0".

db.mails.find({"subject": { "\$regex": "Wall Street Journal"}}).count()

```
> db.mails.find({"subject": {"$regex": "Wall Street Journal"}}).count()
< 4
>
```

db.mails.find({"subject": { "\$regex": "Wall Street Journal"}}, {"sender": 1, "subject": 1, "_id": 0).limit(10)

db.mails.find({"subject": "Wall Street Journal"}).count()

```
db.mails.find({"subject": "Wall Street Journal"}).count()

< 0
> |
```

10. ¿Cuántos correos tienen como remitente un correo con dominio @enron.com?

La cantidad de correos asciende a los 2431. Se adjuntan capturas de pantalla con la verificación y además, en caso de querer saber cuántos de esos correos asociados a remitentes son únicos se debe usar el comando "distinct".

db.mails.find({"sender": { "\$regex": "@enron.com"}}).count()

```
db.mails.find({"sender": {"$regex": "@enron.com"}}).count()

( 2431
```

db.mails.find({"sender": { "\$regex": "@enron.com"}}, {"sender": 1, "subject": 1, "_id": 0).limit(10)

```
db.mails.find(("sender": ("Sreyex": "@enron.com")), ("sender": 1, "subject": 1, *_id": 0)).limit(10)
{    sender: 'rosalee.fleming@enron.com',
    subject: 'Re: Gathering Place Speaking Invitation' )
{        sender: 'tori.wells@enron.com',
        subject: 'Wall Street Journal Millennium Forum' )
{        sender: 'rosalee.fleming@enron.com',
        subject: 'RELL''s e-mail address' )
{        sender: 'rosalee.fleming@enron.com',
        subject: 'Re: EXECUTIVE COMMITTEE MEZINGS - MONDAY, JANUARY 17' )
{        sender: 'rosalee.fleming@enron.com',
        subject: 'Re: Sports Arens Deal' )
{        sender: 'rosalee.fleming@enron.com',
        subject: 'Re: Friday, September 29, 2000' )
{        sender: 'rosalee.fleming@enron.com',
        subject: 'Re: Frosalee.fleming@enron.com',
        subject: 'Re: World Economic Forum, Melbourne, Australia' )
{        sender: 'rosalee.fleming@enron.com',
        subject: 'Re: EXECUTIVE COMMITTEE MEZING - MONDAY, AUGUST 21' )
{        sender: 'rosalee.fleming@enron.com',
        subject: 'Re: EXECUTIVE COMMITTEE MEZING - MONDAY, AUGUST 21' )
}
```

db.mails.distinct ("sender", {"sender": { "\$regex": "@enron.com"}})

```
db.mails.distinct("sender", ("sender": ("$regex": "$enron.com")))

(['.elizondo@enron.com',
'.palmer@enron.com',
'.do.mron@enron.com',
'a..davis@enron.com',
'a..davis@enron.com',
'a..shankman@enron.com',
'a..shankman@enron.com',
'a.shankman@enron.com',
'administration.enron@enron.com',
'administration.enron@enron.com',
'administration.enron@enron.com',
'administration.om',
'administration.om',
'amyle@enron.com',
'amyle@enron.com',
'amyle@enron.com',
'amyle@enron.com',
'amyle@enron.com',
'amyle@enron.com',
'ansstasia.aourik@enron.com',
'andrew.fastow@enron.com',
'andrew.fastow@enron.com',
'andrew.fastow@enron.com',
'andrew.kennaski@enron.com',
```

------FIN -------